

Pie-Lab 2025年暑期培训

李秋予

Pie-Lab

北京理工大学计算机学院

北京市海淀区中关村南大街

786362411@qq.com

Abstract

以下是使用扩散模型对CIFAR-10图像训练并生成图像的实验报告，包括数学原理简述、模型结构设计、实现细节与关键代码说明、评估以及总结与反思。

1 数学原理

扩散模型（Diffusion Models）在近几年成为了生成对抗网络（GAN）之外的另一重要生成模型方向。其核心理念可概括为：「先把一张清晰的图像逐渐加噪，最终变成纯随机噪声；然后训练神经网络逆向地一步步清除噪声，还原到清晰的原图」。这一核心机制体现了从有序到无序、再从无序到有序的双向转换过程。与传统的直接生成方法相比，这种基于渐进去噪的生成范式具有更高的数学可控性和生成稳定性。相较于生成对抗网络的博弈论框架，扩散模型采用基于似然最大化的训练目标，避免了训练不稳定和模式坍塌等问题。这种方法使得扩散模型在理论分析和实际应用中展现出更强的鲁棒性。

1.1 数学框架

扩散模型基于两个马尔可夫过程：

- 正向扩散过程**：将数据分布 $q(\mathbf{x}_0)$ 逐步转换为标准高斯分布
- 逆向生成过程**：从标准高斯分布逐步还原到数据分布

马尔可夫扩散过程：设 $\{\mathbf{x}_t\}_{t=0}^T$ 为随机过程，若转移核为高斯分布：

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \mu_t(\mathbf{x}_{t-1}), \Sigma_t)$$

则该过程满足马尔可夫性质。

1.2 正向扩散过程的数学理论

1. 扩散过程的严格定义

正向扩散过程：给定数据分布 $q(\mathbf{x}_0)$ ，正向扩散过程定义为马尔可夫链：

$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1})$$

其中转移核为：

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I})$$

这里 $\{\beta_t\}_{t=1}^T$ 是预定义的方差调度序列，满足 $0 < \beta_1 < \beta_2 < \dots < \beta_T < 1$ 。

2. 累积扩散的闭式解

重参数化定理: 定义 $\alpha_t = 1 - \beta_t$ 和 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$, 则对任意时刻 t , 有:

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

证明: 采用数学归纳法证明 $q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$ 。

基础步骤: 当 $t = 1$ 时,

$$\mathbf{x}_1 = \sqrt{\alpha_1} \mathbf{x}_0 + \sqrt{1 - \alpha_1} \epsilon_0 \quad (1)$$

其中 $\epsilon_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 故

$$q(\mathbf{x}_1 | \mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_1} \mathbf{x}_0, (1 - \alpha_1) \mathbf{I}) \quad (2)$$

此时 $\bar{\alpha}_1 = \alpha_1$, 命题成立。

归纳步骤: 假设对 $t - 1$ 成立, 即

$$q(\mathbf{x}_{t-1} | \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0, (1 - \bar{\alpha}_{t-1}) \mathbf{I}) \quad (3)$$

根据正向扩散过程定义:

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \epsilon_{t-1} \quad (4)$$

将归纳假设代入得:

$$\mathbf{x}_t = \sqrt{\alpha_t} \left(\sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1}} \epsilon' \right) + \sqrt{1 - \alpha_t} \epsilon_{t-1} \quad (5)$$

其中 $\epsilon' \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

利用独立高斯随机变量的线性组合性质:

$$\sqrt{\alpha_t(1 - \bar{\alpha}_{t-1})} \epsilon' + \sqrt{1 - \alpha_t} \epsilon_{t-1} \sim \mathcal{N}(\mathbf{0}, [\alpha_t(1 - \bar{\alpha}_{t-1}) + (1 - \alpha_t)] \mathbf{I}) \quad (6)$$

注意到:

$$\begin{aligned} \alpha_t(1 - \bar{\alpha}_{t-1}) + (1 - \alpha_t) &= \alpha_t - \alpha_t \bar{\alpha}_{t-1} + 1 - \alpha_t \\ &= 1 - \alpha_t \bar{\alpha}_{t-1} \\ &= 1 - \bar{\alpha}_t \end{aligned}$$

因此最终得到:

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}) \quad (7)$$

直接采样公式: 可通过如下方式直接从 x_0 采样 x_t :

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, 1) \quad (8)$$

1.3 逆向扩散过程

1. 逆向过程的构造

逆向扩散的目标是学习联合分布:

$$p_0(x_{0:T}) = p(x_T) \prod_{t=1}^T p_0(x_{t-1} | x_t) \quad (9)$$

其中 $p(x_T) = \mathcal{N}(0, 1)$ 为先验分布。

2. 后验分布的精确推导

后验分布的解析形式:正向扩散的后验分布为:

$$q(x_{t-1}|x_t, x_0) = \mathcal{N}\left(x_{t-1}; \hat{\mu}_t(x_t, x_0), \hat{\beta}_t \mathbf{I}\right) \quad (10)$$

$$\begin{aligned} \text{其中: } \hat{\mu}_t(x_t, x_0) &= \frac{\sqrt{\alpha_{t-1}}\beta_t}{1-\bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t \\ \hat{\beta}_t &= \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t \end{aligned}$$

3. 噪声预测的参数化

在实际应用中, 无法直接获得 x_0 。因此引入噪声预测网络 $\epsilon_\theta(x_t, t)$ 。

噪声预测等价性:若定义:

$$\hat{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t) \right) \quad (11)$$

则逆向过程的均值可表示为:

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) \quad (12)$$

详细推导过程:

1. 从真实后验均值出发:

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\alpha_{t-1}}\beta_t}{1 - \bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t \quad (13)$$

2. 由重参数化公式:

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon \quad (14)$$

可得:

$$x_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon \right) \quad (15)$$

3. 当使用神经网络预测 ϵ 时:

$$\epsilon \approx \epsilon_\theta(x_t, t) \quad (16)$$

因此:

$$\hat{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t) \right) \quad (17)$$

$$\begin{aligned} \text{4. 将}\hat{x}_0\text{代入真实后验均值并整理系数: } \mu_\theta(x_t, t) &= \frac{\sqrt{\alpha_{t-1}}\beta_t}{1-\bar{\alpha}_t} \left(\frac{x_t - \sqrt{1-\bar{\alpha}_t}\epsilon_\theta}{\sqrt{\bar{\alpha}_t}} \right) + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t \\ &= \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) \end{aligned}$$

1.4 模型结构设计

扩散模型的整体架构可以分为三个核心模块: 扩散过程模块、SimpleUnet网络模块以及训练与可视化模块

1. 扩散过程模块

前向扩散过程建立了噪声添加机制。该过程通过预定义的噪声调度参数 $-t$, 将原始图像 x_0 从初始的(batch-size, 3, 32, 32)维度逐步转化为高斯噪声。具体实现中, `sqrt-alphas-cumprod`和`sqrt-one-minus-alphas-cumprod`这两个关键参数被重塑为(batch-size, 1, 1, 1)的维度, 使得每个样本的所有像素都能按照相同的时间步参数进行噪声混合。例如, 在处理128张CIFAR-10图像时, 系统会为每个批次生成独立的噪声矩阵, 通过广播机制与图像数据进行逐元素线性组合, 最终输出与输入同维度的加噪图像 x_t 。

反向去噪过程通过训练好的神经网络预测噪声, 并利用推导出的后验分布公式逐步去除噪声。特别值得注意的是, 在反向过程的早期阶段会引入适当的随机性, 以增强生成样本的多

样性，而在最后一步则采用确定性更新以确保生成质量。其核心在于构建了一个从噪声到清晰图像的渐进式转换路径。该过程以(batch-size, 3, 32, 32)的纯噪声输入为起点，通过T次迭代逐步去除噪声。每次迭代中，模型首先将当前时间步t从标量转换为(1,)形状的张量，以便与预计算参数的维度匹配。

2.SimpleUnet网络模块

SimpleUnet网络模块构成了整个模型的核心架构，这个U型网络从输入端的(batch-size, 3, 32, 32)张量开始，通过四个下采样块逐步将空间分辨率降至2*2，同时通道数从64递增到1024。每个下采样块内部包含两个卷积层，中间通过批归一化和ReLU激活函数连接。在上采样路径中，系统通过转置卷积逐步恢复分辨率，同时将编码器路径中保存的对应层特征与当前特征在通道维度拼接。例如，在从8*8上采样到16*16时，系统会将当前512通道的特征与编码器路径保存的512通道特征拼接，形成1024通道的中间表示，再通过卷积降回512通道。

3.TimeEmbedding模块

TimeEmbedding模块的设计实现了时间信息的有效编码。该模块将标量时间步t转换为32维的连续向量表示，具体过程包含两个阶段：首先通过指数函数生成一组从高频到低频变化的基频，然后将输入时间步与这些基频相乘得到位置编码。在实现上，32维的输出向量会被进一步通过线性层投影，使其维度能够与不同深度的特征图通道数相匹配。

4.训练与可视化模块

训练与可视化模块实现了模型的端到端训练和生成过程的可视化。在训练阶段，系统维护着多个维度转换过程：输入图像被归一化到[-1,1]范围，噪声预测网络的输出被约束在与目标噪声相同的维度空间。训练过程采用噪声预测损失函数，通过最小化预测噪声与实际噪声之间的均方误差来优化网络参数。可视化阶段则将生成的(batch-size, 3, 32, 32)张量首先被反归一化到[0,1]范围，然后调整通道顺序为HWC格式，最后缩放为0-255的整数像素值。在展示生成过程时，系统会从T个时间步中均匀采样20个关键步骤，将每个步骤的中间结果按照5*4的网格排列，形成直观的扩散过程可视化。这种可视化不仅有助于理解模型的运作机制，也为调试和优化提供了直观依据。

2 可视化展示




Figure 1: 训练结果可视化

2.1 最终模型下20个时间步的渐变过程

2.2 不同训练周期下图像生成效果展示

3 总结与分析

从训练曲线来看，这个扩散模型在CIFAR-10数据集上展现出了良好的收敛性。损失曲线从初始的0.2左右快速下降，在20个epoch后趋于稳定，最终稳定在0.03附近，表明模型成功掌




Figure 2: 最终模型下20个时间步的渐变过程



Figure 3: epoch=10

握了从噪声中重建图像的核心能力。训练时间曲线也有较高稳定性，每个epoch耗时基本维持在49-50秒之间，仅在60个epoch附近出现微小波动。

观察训练过程中生成的样本图像，可以看到模型能力的渐进式提升。在早期epoch（如10-20）生成的图像基本是模糊的色块和噪点，仅能隐约辨认出一些基本形状；到中期epoch（30-50）开始出现物体轮廓；后期epoch（60-80）的图像则展现出更多细节和色彩分布。

最终可视化生成过程展示的20步去噪序列（ $t=1$ 到 $t=1000$ ）呈现了模型如何从纯噪声逐步构建出有意义图像的全过程，验证了模型对数据分布的建模能力。

扩散模型因其迭代式生成特性本就比单次前向的模型更耗时，其时间消耗也高于常规生成模型，这是扩散模型固有的特性，因为需要运行多次去噪步骤才能得到最终结果。




Figure 4: epoch=20




Figure 5: epoch=30



Figure 6: epoch=40




Figure 7: epoch=50



Figure 8: epoch=60



Figure 9: epoch=70



Figure 10: epoch=80




Figure 11: epoch=90




Figure 12: epoch=100